

Cursul 11

Valori și vectori proprii pentru matrice simetrice. Forme pătratice. Descompunerea SVD a unei matrice

11.1 Valori și vectori proprii pentru matrice simetrice. Descompunerea ortogonală a unei matrice simetrice

Reamintim că o matrice pătratică $M \in \mathbb{R}^{n \times n}$ cu proprietatea că $M^T = M$ se numește *matrice simetrică*.

În machine learning matricele simetrice studiate sunt cel mai adesea matrice obținute dintr-o matrice de date $A \in \mathbb{R}^{m \times n}$ care stochează pe coloane datele pentru n entități. Fiecare entitate are m caracteristici, numite atribute: $A = [X_1 | X_2 | \dots | X_n]$.

De exemplu, în diagnosticarea inteligentă sau în studiul eficacității unor medicamente în tratamentul unei boli, entitățile sunt n persoane. Pentru fiecare individ se înregistrează valorile pentru un set de m analize medicale (attribute ale indivizilor). Dacă după constituirea matricei de date se calculează versorul fiecărei coloane și se notează cu B matricea $B = [X_1^0 | X_2^0 | \dots | X_n^0]$, atunci matricea simetrică $M = B^T B$ are ca elemente $M_{ij} = \langle X_i^0, X_j^0 \rangle$. Cu alte cuvinte, un element M_{ij} indică similaritatea dintre indivizii i și j . Pe de altă parte, elementele N_{ij} ale matricei $N = B B^T$ indică similaritatea dintre atribute. Informația importantă codificată de matricea de date A se extrage din valorile proprii și vectorii proprii corespunzători ai matricei simetrice M , respectiv N .

Să studiem particularitățile matricelor simetrice comparativ cu matricele pătratice generale, nesimetrice.

În continuare vom presupune că \mathbb{R}^n este înzestrat cu produsul scalar standard $\langle \cdot, \cdot \rangle$ și că elementele sale sunt vectori coloană. De asemenea, vom interpreta produsul Av , dintre o matrice pătratică $A \in \mathbb{R}^{n \times n}$ și un vector coloană $v \in \mathbb{R}^n$, ca fiind vectorul w ce reprezintă efectul unui operator liniar $L : \mathbb{R}^n \rightarrow \mathbb{R}^n$, a cărui matrice în baza canonică este A , asupra vectorului v . Deci, în loc de $L(v)$ scriem Av .

Propoziția 11.1.1 Dacă $A \in \mathbb{R}^{n \times n}$ este o matrice pătratică, atunci are loc următoarea relație:

$$\langle Av, w \rangle = \langle v, A^T w \rangle, \forall v, w \in \mathbb{R}^n. \quad (11.1)$$

Demonstrație: Exprimând produsul scalar standard astfel $\langle x, y \rangle = x^T y$, membrul stâng al egalității ce dorim să o demonstrăm devine

$$\langle Av, w \rangle = (Av)^T w = v^T A^T w,$$

iar cel drept este

$$\langle v, A^T w \rangle = v^T (A^T w) = v^T A^T w,$$

deci $\langle Av, w \rangle = \langle v, A^T w \rangle$. □

Observația 11.1.1 Dacă A este o matrice simetrică, atunci, din $A^T = A$ și relația (11.1), rezultă

$$\langle Av, w \rangle = \langle v, Aw \rangle, \quad \forall v, w \in \mathbb{R}^n. \quad (11.2)$$

Să enunțăm particularitățile valorilor și vectorilor proprii pentru matrice simetrice:

Propoziția 11.1.2 Polinomul caracteristic al unei matrice simetrice $A \in \mathbb{R}^{n \times n}$ are toate cele n rădăcini reale, adică o matrice simetrică are n valori proprii. În plus, dimensiunea fiecărui subspațiu propriu S_λ coincide cu ordinul de multiplicitate m_λ al valorii proprii corespunzătoare, adică $\dim(S_\lambda) = m_\lambda$ pentru orice valoare proprie λ .

Propoziția 11.1.3 Pentru orice matrice simetrică $A \in \mathbb{R}^{n \times n}$, la valori proprii distincte corespund vectori proprii ortogonali.

Demonstrație: Fie $\lambda_1 \neq \lambda_2$ două valori proprii distincte ale matricei simetrice A și $v_1 \in S_{\lambda_1}$, $v_2 \in S_{\lambda_2}$ doi vectori proprii corespunzători, adică $Av_1 = \lambda_1 v_1$, $Av_2 = \lambda_2 v_2$. Din proprietatea (11.2) a matricelor simetrice, avem că

$$\langle Av_1, v_2 \rangle = \langle v_1, Av_2 \rangle,$$

ceea ce este echivalent cu

$$\langle \lambda_1 v_1, v_2 \rangle = \langle v_1, \lambda_2 v_2 \rangle$$

sau

$$\lambda_1 \langle v_1, v_2 \rangle = \lambda_2 \langle v_1, v_2 \rangle \Leftrightarrow (\lambda_1 - \lambda_2) \langle v_1, v_2 \rangle = 0.$$

Cum $\lambda_1 \neq \lambda_2$, rezultă că $\lambda_1 - \lambda_2 \neq 0$, deci $\langle v_1, v_2 \rangle = 0$, adică $v_1 \perp v_2$, căci v_1, v_2 sunt vectori proprii, deci **nenuli**. □

Fie $A \in \mathbb{R}^{n \times n}$ o matrice simetrică.

• Polinomul caracteristic al lui A , $P_n(\lambda) = \det(A - \lambda I_n)$, având n valori proprii (simple sau multiple), admite descompunerea:

$$P_n(\lambda) = (-1)^n (\lambda - \lambda_1)^{k_1} (\lambda - \lambda_2)^{k_2} \cdots (\lambda - \lambda_s)^{k_s}, \quad k_1 + k_2 + \cdots + k_s = n,$$

unde λ_i este rădăcină de ordin $m_{\lambda_i} = k_i$, $i = \overline{1, s}$.

- Pentru fiecare valoare proprie λ se determină subspațiul propriu corespunzător,

$$S_\lambda = \{v \in \mathbb{R}^n \mid Av = \lambda v \Leftrightarrow (A - \lambda I_n)v = 0\}.$$

• Deoarece dimensiunea subspațiului propriu S_{λ_i} este egală cu ordinul de multiplicitate, k_i , al lui λ_i , determinăm o bază arbitrară \mathcal{B}_i în S_{λ_i} (care conține k_i vectori) și apoi o ortonormăm folosind procedeul Gram–Schmidt și obținem baza ortonormată \mathcal{B}'_i , $i = \overline{1, s}$.

• Dacă $\mathcal{B}'_1 = \underbrace{(u_1, u_2, \dots, u_{k_1})}_{k_1 \text{ vectori}}$, $\mathcal{B}'_2 = \underbrace{(u_{k_1+1}, \dots, u_{k_1+k_2})}_{k_2 \text{ vectori}}$, $\mathcal{B}'_s = \underbrace{(u_{n-k_s+1}, \dots, u_n)}_{k_s \text{ vectori}}$ sunt baze ortonormate în subspațiile proprii $S_{\lambda_1}, S_{\lambda_2}, \dots, S_{\lambda_s}$, concatenând aceste baze ortonormate formate din vectori proprii ai matricei A , obținem o bază ortonormată în \mathbb{R}^n ,

$$\mathcal{B}' = (u_1, u_2, \dots, u_{k_1}, u_{k_1+1}, \dots, u_{k_1+k_2}, \dots, u_n),$$

deoarece vectorii din bazele \mathcal{B}'_i sunt ortonormați și pentru că la valori proprii distincte corespund vectori proprii ortogonali, adică orice vector din \mathcal{B}'_i este ortogonal pe orice vector din \mathcal{B}'_j , $i \neq j$.

• Notăm cu $T_{\mathcal{B}\mathcal{B}'}$ matricea de trecere de la baza canonică $\mathcal{B} = \mathcal{B}_c$ din \mathbb{R}^n la baza ortonormată \mathcal{B}' formată din vectori proprii ai matricei A . Aceasta este o matrice ortogonală, fiind matricea de trecere dintre două baze ortonormate, deci $T_{\mathcal{B}\mathcal{B}'}^{-1} = T_{\mathcal{B}\mathcal{B}'}^T$ (reamintim că inversa unei matrice ortogonale este chiar transpusa sa).

- Notând cu D matricea diagonală a valorilor proprii,

$$D = \text{diag}(\underbrace{\lambda_1, \dots, \lambda_1}_{k_1 \text{ ori}}, \underbrace{\lambda_2, \dots, \lambda_2}_{k_2 \text{ ori}}, \dots, \underbrace{\lambda_s, \dots, \lambda_s}_{k_s \text{ ori}}),$$

rezultă că matricea simetrică A este similară cu matricea diagonală D și, în plus, matricea T din relația de similaritate este matricea ortogonală $T_{\mathcal{B}\mathcal{B}'}$, adică are loc relația:

$$A = T_{\mathcal{B}\mathcal{B}'} D T_{\mathcal{B}\mathcal{B}'}^{-1} = T_{\mathcal{B}\mathcal{B}'} D T_{\mathcal{B}\mathcal{B}'}^T.$$

Astfel, suntem conduși la unul din cele mai importante rezultate aplicative din algebra liniară și anume:

Propoziția 11.1.4 Dacă $A \in \mathbb{R}^{n \times n}$ este o matrice simetrică ce are valorile proprii λ_i cu ordinele de multiplicitate k_i , $i = \overline{1, s}$, $k_1 + k_2 + \dots + k_s = n$, atunci există o bază ortonormată \mathcal{B}' în \mathbb{R}^n formată din vectori proprii ai lui A și notând cu Q matricea de trecere de la baza canonică la baza \mathcal{B}' , matricea A este similară cu matricea

$$D = \text{diag}(\underbrace{\lambda_1, \dots, \lambda_1}_{k_1 \text{ ori}}, \dots, \underbrace{\lambda_s, \dots, \lambda_s}_{k_s \text{ ori}}), \quad (11.3)$$

iar relația de similaritate este

$$A = Q D Q^T. \quad (11.4)$$

Definiția 11.1.1 Descompunerea unei matrice simetrice A în forma $A = Q D Q^T$, unde D este matricea diagonală a valorilor proprii ale lui A și $Q = T_{\mathcal{B}\mathcal{B}'}$ este o matrice ortogonală, se numește **descompunere ortogonală**.

Să ilustrăm această descompunere printr-un exemplu:

Exemplul 1. Să se determine valorile proprii și subspațiile proprii pentru matricea simetrică

$$A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 3 \end{bmatrix}.$$

Să se determine apoi câte o bază ortonormată în fiecare subspațiu propriu al lui A și o bază ortonormată în \mathbb{R}^3 formată din vectori proprii ai lui A . Să se scrie descompunerea ortogonală a matricei A .

- Valorile proprii ale lui A sunt $\lambda_{1,2} = 1, \lambda_3 = 7$;
- Subspațiile proprii corespunzătoare:

$$S_{\lambda=1} = \{v = (x, y, z)^T : Av = 1v \Leftrightarrow (A - 1I_3)v = 0\}.$$

Avem

$$(A - 1I_3)v = 0 \iff \begin{bmatrix} 2 & 2 & 2 \\ 2 & 2 & 2 \\ 2 & 2 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

Rezolvând sistemul de mai sus, obținem

$$S_{\lambda=1} = \{v = (-\alpha - \beta, \alpha, \beta)^T = \alpha(-1, 1, 0)^T + \beta(-1, 0, 1)^T : \alpha, \beta \in \mathbb{R}\}.$$

Bază în acest subspațiu este $\mathcal{B}_1 = (v_1 = (-1, 1, 0)^T, v_2 = (-1, 0, 1)^T)$. Evident că baza \mathcal{B}_1 nu este ortonormată. Aplicând procedeul Gram-Schmidt, obținem baza

$$\mathcal{B}'_1 = \left(q_1 = \frac{1}{\sqrt{2}}(-1, 1, 0)^T, q_2 = \frac{1}{\sqrt{6}}(-1, -1, 2)^T \right).$$

Pentru a determina subspațiul propriu $S_{\lambda=7}$ determinăm soluțiile sistemului

$$(A - 7I_3)v = 0 \iff \begin{bmatrix} -4 & 2 & 2 \\ 2 & -4 & 2 \\ 2 & 2 & -4 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

Alegem drept determinant principal determinantul constituit din elementele de intersecție ale liniilor 1,2 cu coloanele 1,2. Astfel, $z = \alpha$ este necunoscută secundară și obținem

$$S_{\lambda=7} = \{v = \alpha(1, 1, 1)^T : \alpha \in \mathbb{R}\}.$$

O bază ortonormată în $S_{\lambda=7}$ este

$$\mathcal{B}'_2 = \left(q_3 = \frac{1}{\sqrt{3}}(1, 1, 1)^T \right),$$

iar $\mathcal{B}' = \mathcal{B}'_1 \cup \mathcal{B}'_2 = (q_1, q_2, q_3)$ este o bază ortonormată în \mathbb{R}^3 formată din vectori proprii ai matricei A . Notând

$$Q = [q_1 | q_2 | q_3] = \begin{bmatrix} -\frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ 0 & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{3}} \end{bmatrix},$$

obținem descompunerea ortogonală $A = QDQ^T$, unde $D = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 7 \end{bmatrix}$.

11.2 Forme pătratică

În inteligența artificială deseori într-o etapă a unui algoritm trebuie determinate punctele în care o funcție $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$ de clasă C^2 ia valoarea minimă sau maximă. Problema aflării punctelor de minim sau maxim se numește problemă de optimizare și se notează astfel:

$$\operatorname{argmin} f(x), x \in D, \quad \operatorname{argmax} f(x), x \in D$$

și se citește: să se determine argumentul $x \in D$ care minimizează funcția f sau să se determine argumentul $x \in D$ care maximizează funcția f .

Exemple de probleme de optimizare: minimizarea erorii în clasificare sau determinarea drumului de lungime minimă pe care trebuie să îl parcurgă un agent inteligent pentru a deservi n noduri/puncte de lucru etc.

Decizia dacă un punct x_0 din D este punct de minim sau maxim pentru o funcție f se ia analizând o formă pătratică asociată funcției f și anume $\varphi(v) = d_{x_0}^2 f(v, v)$, unde $d_{x_0}^2 f$ este diferențiala de ordinul 2 a funcției f în punctul x_0 .

Considerăm spațiul vectorial \mathbb{R}^n înzestrat cu produsul scalar standard $\langle v, w \rangle = v^T w$ și \mathcal{B} o bază ortonormată în \mathbb{R}^n (de obicei, baza canonică; vom face convenția că dacă nu este precizat în context cine este baza \mathcal{B} , aceasta va fi considerată baza canonică).

Definiția 11.2.1 Fie $A = (a_{ij})_{i,j=\overline{1,n}}$ o matrice simetrică. Aplicația $q : \mathbb{R}^n \rightarrow \mathbb{R}$, definită prin

$$q(v_{\mathcal{B}}) = \langle v_{\mathcal{B}}, Av_{\mathcal{B}} \rangle = v_{\mathcal{B}}^T Av_{\mathcal{B}}, \quad (11.5)$$

se numește *formă pătratică*.

Dacă un vector arbitrar $v \in \mathbb{R}^n$ are relativ la baza \mathcal{B} coordonatele $v_{\mathcal{B}} = (x_1, x_2, \dots, x_n)^T$, atunci expresia analitică a formei pătratică în această bază este:

$$q(v_{\mathcal{B}}) = \begin{bmatrix} x_1 & x_2 & \dots & x_n \end{bmatrix} \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}. \quad (11.6)$$

Efectuând produsele, obținem

$$q(v_B) = a_{11}x_1^2 + a_{22}x_2^2 + \cdots + a_{nn}x_n^2 + 2a_{12}x_1x_2 + \cdots + 2a_{1n}x_1x_n + \cdots + 2a_{n-1n}x_{n-1}x_n.$$

Expresia precedentă ilustrează de ce funcția q se numește formă pătratică: expresia ei este o sumă de termeni de gradul 2 în x_1, x_2, \dots, x_n , adică ceea ce se numește **polinom omogen de gradul 2**.

Exemplul 2. Formă pătratică q determinată de matricea simetrică $A = \begin{bmatrix} -2 & 1 \\ 1 & 3 \end{bmatrix}$ este

$$q(x_1, x_2)^T \stackrel{\text{not.}}{=} q(x_1, x_2) = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} -2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = -2x_1^2 + 2x_1x_2 + 3x_2^2.$$

În cele ce urmează în loc de $q(x_1, x_2, \dots, x_n)^T$ vom scrie simplu $q(x_1, x_2, \dots, x_n)$.

Dacă cunoaștem expresia analitică a unei forme pătratice $q : \mathbb{R}^n \rightarrow \mathbb{R}$, adică un polinom omogen de gradul 2 în x_1, x_2, \dots, x_n , matricea simetrică ce o definește se determină astfel:

- coeficienții termenilor $x_1^2, x_2^2, \dots, x_n^2$ reprezintă elementele $a_{11}, a_{22}, \dots, a_{nn}$ ale matricei simetrice A , adică elementele de pe diagonala principală a lui A ;
- coeficienții produselor $x_i x_j$ împărțiți la 2 sunt elementele a_{ij} și a_{ji} ale matricei A , pentru $i, j = \overline{1, n}, i \neq j$.

Exemplul 3. Se dă forma pătratică $q : \mathbb{R}^3 \rightarrow \mathbb{R}$, definită prin

$$q(x_1, x_2, x_3) = 2x_1^2 + 3x_1x_2 + 6x_1x_3 - 5x_2^2 - 8x_2x_3 + x_3^2.$$

Matricea simetrică asociată este

$$A = \begin{bmatrix} 2 & \frac{3}{2} & 3 \\ \frac{3}{2} & -5 & -4 \\ 3 & -4 & 1 \end{bmatrix}.$$

O formă pătratică ia valori reale care pot fi pozitive, negative sau zero. Se observă că $q(0) = 0$, deci o formă pătratică aplică vectorul nul $0 = (0, 0, \dots, 0)$ în numărul real 0.

• Forma pătratică $q : \mathbb{R}^n \rightarrow \mathbb{R}$ care ia valori pozitive, $q(v) > 0$, oricare ar fi vectorul $v \in \mathbb{R}^n \setminus \{0\}$, se numește **formă pătratică pozitiv definită**.

• Dacă $q(v) \geq 0$, pentru orice $v \in \mathbb{R}^n$, atunci q se numește **formă semipozitiv definită** (mai precis, în acest caz q poate lua valoarea zero și pentru vectori nenuli).

• Dacă $q(v) < 0$, oricare ar fi $v \in \mathbb{R}^n \setminus \{0\}$, atunci q se numește **formă negativ definită**, iar dacă $q(v) \leq 0, \forall v \in \mathbb{R}^n$, forma q se numește **seminegativ definită**.

• Dacă pentru anumiți vectori q ia valori pozitive, iar pe alții valori negative, atunci q se numește **formă pătratică nedefinită**.

Analizând expresia analitică a formei pătratice din Exemplul 3 este greu să ne pronunțăm dacă ea este pozitiv definită, negativ definită sau nedefinită. Este însă foarte simplu să indicăm tipul formei pătratice dacă ea conține doar termeni în x_i^2 , $i = \overline{1, n}$.

Exemplul 4. Forma pătratică $q(x_1, x_2, x_3) = -3x_1^2 - x_2^2 - 4x_3^2$ este negativ definită, forma pătratică $q(x_1, x_2, x_3) = 2x_1^2 - x_2^2 + 6x_3^2$ este nedefinită, deoarece $q(1, 0, 1) = 8 > 0$ și $q(0, 1, 0) = -1 < 0$, iar forma $q(x_1, x_2, x_3) = x_1^2 + x_2^2$ este semipozitiv definită (ea nu este pozitiv definită, căci ia valoarea 0 și pentru vectori nenuli, de exemplu $q(0, 0, 1) = 0$).

Observăm că putem deduce rapid tipul unei forme pătratice dacă ea este definită de o matrice diagonală, care evident este simetrică:

$$\begin{aligned} q(x_1, x_2, \dots, x_n) &= [x_1 \ x_2 \ \dots \ x_n] \begin{bmatrix} d_1 & 0 & \dots & 0 \\ 0 & d_2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & d_n \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \\ &= d_1 x_1^2 + d_2 x_2^2 + \dots + d_n x_n^2, \quad d_i \in \mathbb{R}. \end{aligned}$$

O formă pătratică a cărei matrice de definiție este diagonală se zice că este în *forma canonică*.

Să exploatăm faptul că orice matrice simetrică A este similară cu o matrice diagonală, adică există $\lambda_1, \lambda_2, \dots, \lambda_n \in \mathbb{R}$, ce sunt valorile proprii ale lui A , și o matrice inversabilă $T = T_{\mathcal{B}\mathcal{B}'}$, ce este matricea de trecere de la baza canonică \mathcal{B} la baza ortonormată \mathcal{B}' , formată din vectori proprii ai lui A , astfel încât $A = TDT^{-1} = T_{\mathcal{B}\mathcal{B}'}DT_{\mathcal{B}\mathcal{B}'}^T$, unde $D = \text{diag}(d_1, d_2, \dots, d_n)$.

Relația de mai sus este echivalentă cu

$$D = T_{\mathcal{B}\mathcal{B}'}^T A T_{\mathcal{B}\mathcal{B}'}. \quad (11.7)$$

Pe de altă parte, relația dintre coordonatele unui vector $v \in \mathbb{R}^n$ relativ la cele două baze este $v_{\mathcal{B}} = T_{\mathcal{B}\mathcal{B}'} v_{\mathcal{B}'}$. Să deducem expresia analitică a formei pătratice q definită de matricea A relativ la baza \mathcal{B}' , formată din vectori proprii ai lui A . Pentru aceasta notăm cu X_1, X_2, \dots, X_n , coordonatele vectorului arbitrar v relativ la baza \mathcal{B}' , adică $v_{\mathcal{B}'} = (X_1, X_2, \dots, X_n)^T$. Avem

$$\begin{aligned} q(v_{\mathcal{B}}) &= \langle v_{\mathcal{B}}, A v_{\mathcal{B}} \rangle = \langle T_{\mathcal{B}\mathcal{B}'} v_{\mathcal{B}'}, A T_{\mathcal{B}\mathcal{B}'} v_{\mathcal{B}'} \rangle \stackrel{(11.1)}{=} \langle v_{\mathcal{B}'}, T_{\mathcal{B}\mathcal{B}'}^T A T_{\mathcal{B}\mathcal{B}'} v_{\mathcal{B}'} \rangle \stackrel{(11.7)}{=} \langle v_{\mathcal{B}'}, D v_{\mathcal{B}'} \rangle \\ &= [X_1 \ X_2 \ \dots \ X_n] \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{bmatrix} \\ &= \lambda_1 X_1^2 + \lambda_2 X_2^2 + \dots + \lambda_n X_n^2. \end{aligned}$$

Am arătat astfel că o formă pătratică definită de o matrice simetrică A asociază unui vector exprimat în baza \mathcal{B} aceeași valoare ca valoarea asociată de forma pătratică definită de matricea diagonală D a valorilor proprii ale lui A aceluiași vector, dar exprimat în baza \mathcal{B}' .

În concluzie, pentru a decide tipul forme pătratice care relativ la baza ortonormată inițială \mathcal{B} are matricea simetrică A , se determină valorile proprii ale lui A .

- **Dacă toate valorile proprii sunt pozitive ($\lambda_i > 0, \forall i = \overline{1, n}$), atunci forma pătratică este pozitiv definită;**
- **Dacă toate valorile proprii sunt mai mari sau egale cu 0, atunci forma pătratică este semipozitiv definită;**
- **Dacă $\lambda_i < 0, \forall i = \overline{1, n}$, atunci forma este negativ definită, respectiv seminegativ definită dacă $\lambda_i \leq 0, \forall i = \overline{1, n}$;**
- **Dacă cel puțin o valoare proprie este pozitivă și alta negativă, atunci forma pătratică este nedefinită.**

Exemplul 5. Se dă forma pătratică $q : \mathbb{R}^2 \rightarrow \mathbb{R}, q(x_1, x_2) = 4x_1^2 - 4x_1x_2 + x_2^2$. Să se determine matricea forme pătratice, valorile ei proprii și să se precizeze tipul forme.

Matricea forme pătratice este

$$A = \begin{bmatrix} 4 & -2 \\ -2 & 1 \end{bmatrix}.$$

Valorile proprii ale lui A sunt $\lambda_1 = 0, \lambda_2 = 5$, deci forma pătratică este semipozitiv definită.

În analiza matematică, unei funcții $f : D \subset \mathbb{R}^n \rightarrow \mathbb{R}$, de clasă C^2 pe D , i se asociază matricea simetrică $\text{Hess}(f)(x_0)$ a derivatelor parțiale de ordinul 2 într-un punct critic x_0 , numită Hessiana funcției f în x_0 . Elementele a_{ij} ale acestei matrice sunt

$$a_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}(x_0), \text{ pentru } i, j = \overline{1, n}.$$

Dacă x_0 este un punct critic al funcției f , adică

$$\frac{\partial f}{\partial x_i}(x_0) = 0, \forall i = \overline{1, n},$$

atunci tipul forme pătratice având ca matrice Hessiana funcției f în punctul x_0 indică dacă punctul x_0 este punct de maxim, punct de minim sau punct șa (este punct critic, dar nu este punct de extrem).

În Fig.11.1 este ilustrat graficul unei forme pătratice

$$q : \mathbb{R}^2 \rightarrow \mathbb{R}, q(x_1, x_2) = \lambda_1 x_1^2 + \lambda_2 x_2^2$$

pentru cazul q – pozitiv definită ($\lambda_1, \lambda_2 > 0$), negativ definită ($\lambda_1, \lambda_2 < 0$), respectiv nedefinită ($\lambda_1 > 0, \lambda_2 < 0$).

Observăm că în primul caz $(0, 0)$ este punct de minim pentru că $q(x_1, x_2) > 0$ pentru orice $v = (x_1, x_2)^T \neq (0, 0)^T$, în al doilea caz este punct de maxim și în al treilea este punct șa. O funcție $f : D \subset \mathbb{R}^2 \rightarrow \mathbb{R}$, de clasă C^r pe D , $r \geq 2$, este aproximată în vecinătatea unui punct critic x_0 de o astfel de formă pătratică și, deci, tipul extremal al punctului critic depinde de tipul punctului $(0, 0)$ pentru forma pătratică asociată.




Fig.11.1: Graficele a trei forme pătratice aduse la forma canonică $q(x_1, x_2) = \lambda_1 x_1^2 + \lambda_2 x_2^2$: în stânga forma este pozitiv definită, în centru forma este negativ definită și în dreapta forma este nedefinită.

11.3 Descompunerea singulară a unei matrice

Necesitatea de a minimiza volumul de informație ce trebuie să fie stocată sau transmisă printr-un canal de comunicație a condus la dezvoltarea unor metode de reducere a dimensiunii acestora (comprimarea datelor). Una din metodele de comprimare a datelor oferite de algebra liniară se bazează pe descompunerea singulară a unei matrice $A \in \mathbb{R}^{m \times n}$.

11.3.1 Noțiuni și rezultate preliminare

Definiția 11.3.1 O matrice simetrică $A \in \mathbb{R}^{n \times n}$ pentru care forma pătratică asociată q este pozitiv definită, adică

$$q(v) = \langle v, Av \rangle > 0, \forall v \in \mathbb{R}^n \setminus \{0\}, \quad (11.8)$$

se numește *matrice pozitiv definită*, iar dacă este verificată relația

$$q(v) = \langle v, Av \rangle \geq 0, \forall v \in \mathbb{R}^n, \quad (11.9)$$

se numește *matrice simetrică semipozitiv definită*.

Propoziția 11.3.1 O matrice simetrică este semipozitiv definită dacă și numai dacă are toate valorile proprii mai mari sau egale cu zero.

Demonstrație: Fie $A \in \mathbb{R}^{n \times n}$ o matrice simetrică semipozitiv definită. Fiind simetrică, A are n valori proprii (distincte sau nu). Fie $\lambda \in \mathbb{R}$ o valoare proprie și v un vector propriu corespunzător, adică $Av = \lambda v$. Au loc următoarele echivalențe:

$$\langle v, Av \rangle \geq 0 \Leftrightarrow \langle v, \lambda v \rangle \geq 0 \Leftrightarrow \lambda \langle v, v \rangle \geq 0.$$

v , fiind vector propriu, este nenul, deci $\langle v, v \rangle > 0$. Astfel, $\lambda \langle v, v \rangle \geq 0$ dacă și numai dacă $\lambda \geq 0$. \square

Considerăm o matrice arbitrară cu m linii și n coloane, $A \in \mathbb{R}^{m \times n}$. Matricele asociate $A^T A$, AA^T sunt matrice pătratice de tip $n \times n$, respectiv $m \times m$ și simetrice, deoarece coincid cu transpusele lor. De exemplu, $(A^T A)^T = A^T (A^T)^T = A^T A$.

Propoziția 11.3.2 Dacă $A \in \mathbb{R}^{m \times n}$ este o matrice de tip $m \times n$, atunci matricele simetrice asociate $A^T A$, AA^T sunt semipozitiv definite.

Demonstrație: Deoarece produsul scalar al unui vector cu el însuși este mai mare sau egal cu zero, avem că pentru orice vector $v \in \mathbb{R}^n$: $\langle Av, Av \rangle \geq 0$. Dar

$$\langle Av, Av \rangle \stackrel{(11.1)}{=} \langle v, A^T A v \rangle,$$

ceea ce implică $\langle v, A^T A v \rangle \geq 0$, $\forall v \in \mathbb{R}^n$, adică matricea $A^T A$ este semipozitiv definită. Analog, $\langle A^T v, A^T v \rangle \geq 0$ și din

$$\langle A^T v, A^T v \rangle \stackrel{(11.1)}{=} \langle v, AA^T v \rangle, \forall v \in \mathbb{R}^m$$

rezultă că și matricea AA^T este semipozitiv definită. \square

Propoziția 11.3.3 Rangul matricei $A^T A$ coincide cu rangul matricei $A \in \mathbb{R}^{m \times n}$.

11.4 Calculul descompunerii singulare a unei matrice

Propoziția 11.4.1 (Descompunerea singulară) Pentru orice matrice $A \in \mathbb{R}^{m \times n}$ de rang r există două matrice ortogonale $U \in \mathbb{R}^{m \times m}$, $V \in \mathbb{R}^{n \times n}$ și numerele reale pozitive

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$$

astfel încât A se descompune în produsul $A = U \Sigma V^T$, adică

$$\underbrace{\underbrace{A}_{m \times n} = \underbrace{U}_{m \times m} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & \sigma_r & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 \end{bmatrix}}_{m \times n}}_{m \times n} \underbrace{V^T}_{n \times n}. \quad (11.10)$$

Definiția 11.4.1 Descompunerea de mai sus se numește **descompunerea singulară** a matricei A (**singular value decomposition, SVD**). Valorile pozitive $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r$ din matricea Σ se numesc **valorile singulare** ale matricei A , vectorii u_i , **vectori singulari stângi**, iar vectorii v_i , **vectori singulari dreپți**, $i = \overline{1, r}$.

Pentru a interpreta descompunerea SVD și pentru a prezenta aplicații ale ei, definim câteva noțiuni și rezultate de calcul matriceal:

• Produsul exterior a doi vectori $u \in \mathbb{R}^m$, $v \in \mathbb{R}^n$ este o matrice de tip $m \times n$ obținută înmulțind vectorul coloană u cu vectorul linie v^T , adică uv^T .

Dacă $u = (x_1, x_2, \dots, x_m)^T$ și $v = (y_1, y_2, \dots, y_n)^T$, atunci produsul lor exterior este

$$uv^T = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix} \begin{bmatrix} y_1 & y_2 & \dots & y_n \end{bmatrix} = \begin{bmatrix} x_1 y_1 & x_1 y_2 & \dots & x_1 y_n \\ x_2 y_1 & x_2 y_2 & \dots & x_2 y_n \\ \vdots & \vdots & \dots & \vdots \\ x_m y_1 & x_m y_2 & \dots & x_m y_n \end{bmatrix}.$$

Prin urmare, matricea produs exterior, $B = uv^T$, are elementele $b_{ij} = x_i y_j$, $i = \overline{1, m}$, $j = \overline{1, n}$.

Dacă vectorii u, v sunt nenuli, atunci coloanele matricei uv^T sunt proporționale, deci rangul matricei B este 1.

Propoziția 11.4.2 Produsul $U\Sigma V^T$ din descompunerea SVD a unei matrice $A \in \mathbb{R}^{m \times n}$ de rang r este egal cu

$$U\Sigma V^T = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T.$$

Prin urmare, ideea de bază a descompunerii SVD a unei matrice $A \in \mathbb{R}^{m \times n}$ de rang r este că matricea A se poate descompune ca o combinație liniară cu coeficienți pozitivi și descrescători a r matrice de rangul 1, $M_j = u_j v_j^T$, $j = \overline{1, r}$:

$$A = U\Sigma V^T = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_r u_r v_r^T.$$

Aproximarea de rang k a matricei A : Dacă în descompunerea SVD a unei matrice ultimele valori singulare sunt mici (aproape de zero), atunci, renunțând la termenii ce le conțin, obținem o aproximare a matricei A :

$$A_k = \sigma_1 (u_1 v_1^T) + \dots + \sigma_k (u_k v_k^T).$$

Matricea aproximare A_k se factorizează astfel:

$$A_k = \underbrace{\begin{bmatrix} u_1 & u_2 & \dots & u_k \end{bmatrix}}_{m \times k} \underbrace{\begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \dots & \vdots \\ 0 & 0 & \dots & \sigma_k \end{bmatrix}}_{k \times k} \underbrace{\begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_k^T \end{bmatrix}}_{k \times n} = U_k \Sigma_k V_k^T$$

și are rangul k .

Ori de câte ori se aproximează un element al unei mulțimi înzestrate cu o distanță (o astfel de mulțime se numește *spațiu metric*) cu alt element al aceleiași mulțimi, ne interesează "cât de bună este acea aproximare", evaluând distanța dintre element și aproximantul său.

În mulțimea matricelor din $\mathbb{R}^{m \times n}$ se definesc diferite norme și atunci $dist(A, B) = \|A - B\|$. O normă este cea definită de produsul scalar a două matrice:

$$\langle A, B \rangle = \text{trace}(A^T B)$$

și anume

$$\|A\| = \sqrt{\langle A, A \rangle} = \sqrt{\text{trace}(A^T A)}.$$

Această normă se numește **norma Frobenius** a unei matrice și pentru a o distinge de alte norme se notează $\|A\|_F$.

Teorema 11.4.1 (Teorema Eckart) Fie matricea $A \in \mathbb{R}^{m \times n}$ și $A_k \in \mathbb{R}^{m \times n}$ aproximarea sa de rang k . Dintre toate matricele $B \in \mathbb{R}^{m \times n}$ de rang k , distanța de la A la B este minimă pentru $B = A_k$, adică

$$\min_{B \mid \text{rang}(B)=k} \|A - B\|_F = \|A - A_k\|_F = \sqrt{\sigma_{k+1}^2 + \dots + \sigma_r^2}.$$

Cu alte cuvinte, A_k este cea mai bună aproximare de rang k a matricei A . Această proprietate se exploatează în numeroase domenii din Computer Science, printre care: comprimarea datelor, în general, și a imaginilor, în particular, information retrieval, machine learning.

Dacă A este o matrice imagine ai cărei pixeli au diverse nivele de gri, între negru și alb, un element al matricei A fiind codul nivelului de gri $c \in \{0, 1, 2, \dots, 255\}$ sau normalizat $c \in [0, 1]$ (depinde de tipul de imagine și limbajul de programare care o citește; de exemplu, în Python imaginile în nivele de gri din mulțimea $\{0, 1, 2, \dots, 255\}$ sunt convertite la citire în imagini cu nivelul de gri în $[0, 1]$, adică dacă codul pentru gri este $c = 135$, el este convertit în $135/256$), atunci, determinând descompunerea SVD a matricei $A = \sum_{i=1}^r \sigma_i u_i v_i^T$ și renunțând la termenii ce au coeficienții $\sigma_{k+1}, \dots, \sigma_r$ suficient de mici în comparație cu $\sigma_1, \sigma_2, \dots, \sigma_k$, obținem o aproximare A_k a imaginii A . Aceasta este o modalitate de comprimare a imaginii în scopul stocării sau transmiterii ei pe un canal de comunicație, adică în locul transmiterii vectorilor $u_1, u_2, \dots, u_r, v_1, v_2, \dots, v_r$ și, respectiv, a valorilor singulare $\sigma_1, \sigma_2, \dots, \sigma_r$ se transmit doar vectorii $u_1, \dots, u_k, v_1, \dots, v_k$ și valorile singulare $\sigma_1, \sigma_2, \dots, \sigma_k, k < r$.

Descompunerea trunchiată A_k a unei imaginii A filtrează o parte din zgomotul conținut în imagine fără a pierde o informație semnificativă din ea.

11.5 Construcția matricelor U, V, Σ din descompunerea SVD

• Construcția matricei V :

Matricea $A^T A$, fiind o matrice de tip $n \times n$ simetrică și semipozitiv definită, are n valori proprii $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$. Construind câte o bază ortonormată în fiecare subspațiu propriu și reunind aceste baze obținem baza ortonormată în \mathbb{R}^n formată din vectori proprii ai matricei $A^T A$, $\mathcal{B}'_n = (v_1, v_2, \dots, v_n)$. Notăm cu $V = [v_1 | v_2 | \dots | v_n]$ matricea de trecere de la baza canonică la baza \mathcal{B}'_n , care evident este matrice ortogonală. Astfel, matricea $A^T A$ este similară cu matricea diagonală a valorilor proprii:

$$M = A^T A = V \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) V^T.$$

Dar cum două matrice similare au același rang, rezultă că

$$\text{rang}(\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)) = \text{rang}(A^T A).$$

Cum $\text{rang}(A^T A) = \text{rang}(A) = r$, matricea diagonală $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ are rangul r , deci doar primele r valori proprii în ordinea descrescătoare sunt nenule:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0 \text{ și } \lambda_{r+1} = \dots = \lambda_n = 0.$$

• **Construcția matricei U :**

Vectorii proprii ortonormați v_1, v_2, \dots, v_r corespund la valori proprii λ_i nenule:

$$A^T A(v_i) = \lambda_i v_i, \quad i = \overline{1, r}.$$

Considerăm vectorii din \mathbb{R}^m , $w_i = Av_i, i = \overline{1, r}$. Să arătăm că sistemul w_1, w_2, \dots, w_r este un sistem ortogonal de vectori:

$$\langle w_i, w_j \rangle = \langle Av_i, Av_j \rangle = \langle v_i, (A^T A)v_j \rangle = \langle v_i, \lambda_j v_j \rangle = \lambda_j \langle v_i, v_j \rangle = \lambda_j \delta_{ij}.$$

Astfel, pentru $i \neq j$, $\langle w_i, w_j \rangle = \lambda_j \cdot 0 = 0$, deci vectorii $w_i, i = \overline{1, r}$, sunt ortogonali. Pentru $i = j$ avem $\langle w_i, w_i \rangle = \lambda_i$, ceea ce este echivalent cu $\|w_i\|^2 = \lambda_i$ sau echivalent

$$\|w_i\| = \sqrt{\lambda_i} = \sigma_i, \quad i = \overline{1, r}.$$

Normând sistemul de vectori (w_1, w_2, \dots, w_r) , obținem sistemul ortonormat de r vectori din \mathbb{R}^m , (u_1, u_2, \dots, u_r) , unde

$$u_i = \frac{w_i}{\|w_i\|} = \frac{w_i}{\sigma_i} = \frac{Av_i}{\sigma_i}, \quad i = \overline{1, r}.$$

Prin urmare, are loc următoarea relație între vectorii ortonormați v_1, v_2, \dots, v_r din \mathbb{R}^n și vectorii ortonormați u_1, u_2, \dots, u_r din \mathbb{R}^m :

$$Av_i = \sigma_i u_i, \quad i = \overline{1, r}.$$

Sistemul de vectori ortonormați (u_1, u_2, \dots, u_r) îl completăm la o bază ortonormată

$$(u_1, u_2, \dots, u_r, u_{r+1}, \dots, u_m)$$

în \mathbb{R}^m și anume:

• Determinăm o bază arbitrară în $\text{Null}(A^T)$. Deoarece A^T are rangul lui A , adică r , rezultă că dimensiunea lui este $m - r$. Baza arbitrară $(t_1, t_2, \dots, t_{m-r})$ se ortonormează cu metoda Gram-Schmidt și obținem din ea baza ortonormată $(u_{r+1}, u_{r+2}, \dots, u_m)$ în $\text{Null}(A^T)$.

• Baza ortonormată (u_{r+1}, \dots, u_m) din $\text{Null}(A^T)$ completează sistemul (u_1, u_2, \dots, u_r) la o bază ortonormată în \mathbb{R}^m , $(u_1, \dots, u_r, u_{r+1}, \dots, u_m)$.

Notăm cu U matricea de trecere de la baza canonică din \mathbb{R}^m la baza ortonormată găsită anterior, (u_1, u_2, \dots, u_m) . Matricea $U = [u_1 | u_2 | \dots | u_m]$ este chiar matricea ortogonală din descompunerea SVD a matricei A .

Etapizarea calculelor pentru determinarea descompunerii singulare a unei matrice

$$A \in \mathbb{R}^{m \times n}$$

- se calculează produsul $M = A^T A$;
- se determină polinomul caracteristic al matricei simetrice semipozitiv definite $M = A^T A$, $P_n(\lambda) = \det(M - \lambda I_n)$, și i se determină rădăcinile $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$;
- se determină câte o bază în fiecare subspațiu propriu al matricei $M = A^T A$, care apoi se ortonormează folosind procedeul Gram-Schmidt; reuniunea acestor baze conduce la o bază ortonormată în \mathbb{R}^n formată din vectori proprii, (v_1, v_2, \dots, v_n) ;
- se constituie matricea $V = [v_1 | v_2 | \dots | v_n]$;
- se separă vectorii v_1, v_2, \dots, v_r ce corespund valorilor proprii nenule $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r$ și se calculează valorile singulare

$$\sigma_i = \sqrt{\lambda_i}, \quad i = \overline{1, r};$$

- se determină vectorii ortonormați u_1, u_2, \dots, u_r din \mathbb{R}^m cu formula

$$u_i = \frac{1}{\sigma_i} A v_i, \quad i = \overline{1, r};$$

- se determină o bază arbitrară în subspațiul $\text{Null}(A^T)$ rezolvând sistemul liniar și omogen $A^T x = 0$. Aplicând procedeul Gram-Schmidt, se ortonormează baza determinată, obținând astfel $m - r$ vectori ortonormați u_{r+1}, \dots, u_m , deoarece dimensiunea lui $\text{Null}(A^T)$ este egală cu $m - r$, adică cu numărul m de coloane ale matricei A^T minus $\text{rang}(A^T) = \text{rang}(A) = r$;
- se constituie matricea $U = [u_1 | u_2 | \dots | u_m]$;
- se scrie descompunerea SVD a matricei A , $A = U \Sigma V^T$, ținând seama că matricea Σ are aceleași dimensiuni ca și A , adică este de tip $m \times n$.

Exemplul 6. Să se determine descompunerea singulară a matricei $A = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix}$.

- Calculăm

$$M = A^T A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

- $P_2(\lambda) = \det(M - \lambda I_2) = (2 - \lambda)^2 - 1$ și $\lambda_1 = 3, \lambda_2 = 1$ (le-am ordonat descrescător).
- Determinăm câte o bază în fiecare subspațiu propriu:

$$S_{\lambda=3} = \{v = \alpha(1, 1)^T, \alpha \in \mathbb{R}\}, \quad \mathcal{B}_1 = ((1, 1)^T),$$

$$S_{\lambda=1} = \{v = \beta(1, -1)^T, \beta \in \mathbb{R}\}, \quad \mathcal{B}_2 = ((1, -1)^T).$$

Vectorii celor două baze sunt ortogonali, deoarece corespund la valori proprii distincte ale unei matrice simetrice ($A^T A$). Îi normăm și obținem baza ortonormată în \mathbb{R}^2

$$\mathcal{B}' = (v_1 = (\sqrt{2}/2, \sqrt{2}/2)^T, v_2 = (\sqrt{2}/2, -\sqrt{2}/2)^T)$$

și matricea

$$V = [v_1 | v_2] = \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \end{bmatrix}.$$

- Calculăm valorile singulare: $\sigma_1 = \sqrt{3}, \sigma_2 = \sqrt{1} = 1$.
- Determinăm coordonatele vectorilor $u_i = \frac{1}{\sigma_i} A v_i, i = 1, 2$, unde 2 este rangul matricei $A^T A$:

$$u_1 = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{2}/2 \\ \sqrt{2}/2 \end{bmatrix} = \begin{bmatrix} \sqrt{6}/3 \\ \sqrt{6}/6 \\ \sqrt{6}/6 \end{bmatrix},$$

$$u_2 = \begin{bmatrix} 1 & 1 \\ 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \sqrt{2}/2 \\ -\sqrt{2}/2 \end{bmatrix} = \begin{bmatrix} 0 \\ -\sqrt{2}/2 \\ \sqrt{2}/2 \end{bmatrix}.$$

- Completăm sistemul ortonormat (u_1, u_2) la o bază ortonormată în \mathbb{R}^3 . Teoretic, ar trebui să determinăm o bază în subspațiul soluțiilor sistemului $A^T x = 0$, adică

$$\begin{bmatrix} 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Notând $x_2 = \gamma$, avem

$$\text{Null}(A^T) = \{v = \gamma(-1, 1, 1)^T : \gamma \in \mathbb{R}\},$$

deci $u_3 = (-1/\sqrt{3}, 1/\sqrt{3}, 1/\sqrt{3})^T$.

În acest caz special am fi putut determina pe $u_3 = u_1 \times u_2$.

- Matricea U este

$$U = [u_1 | u_2 | u_3] = \begin{bmatrix} \frac{\sqrt{6}}{3} & 0 & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{6} & -\frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \end{bmatrix}.$$

- Descompunerea SVD a matricei A este

$$A = \begin{bmatrix} \frac{\sqrt{6}}{3} & 0 & -\frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{6} & -\frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ \frac{2}{2} & -\frac{\sqrt{2}}{2} \end{bmatrix}.$$

11.6 Probleme propuse

1. Să se determine factorizarea $A = QDQ^T$ a matricei simetrice $A = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}$.

2. Matricea

$$A = \begin{bmatrix} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 1 & -1 & 0 \end{bmatrix}$$

admite valoarea proprie 1. Mai admite A și alte valori proprii? Argumentați! Să se factorizeze matricea $A = QDQ^T$, unde Q este o matrice ortogonală și D este o matrice diagonală.

3. Să se factorizeze matricea simetrică $A = \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix}$ în $A = QDQ^T$, unde Q este o matrice ortogonală, iar D este o matrice diagonală.

4. Determinați expresia analitică a formei pătratice $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$, definită de matricea simetrică

$$A = \begin{pmatrix} 2 & 1 & 0 \\ 1 & 3 & -1 \\ 0 & -1 & 2 \end{pmatrix},$$

apoi stabiliți natura acestei forme pătratice.

5. Să se determine matricea formei pătratice $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$, definită prin

$$Q(x_1, x_2, x_3) = 3x_1^2 + 8x_1x_2 - 8x_1x_3 - x_2^2 - 4x_2x_3 + x_3^2,$$

apoi stabiliți natura acestei forme pătratice.

6. Să se aducă forma pătratică $Q(x_1, x_2) = -2\sqrt{2}x_1x_2 + x_2^2$ la forma canonică și apoi să se stabilească natura ei, adică dacă Q este o formă pătratică pozitiv definită, negativ definită sau nedefinită.

7. Dacă matricea unei forme pătratice are valorile proprii $-1, 2, 0$, ce puteți spune despre natura formei pătratice? Justificați!

8. Să determine descompunerea singulară a matricei $A = \begin{bmatrix} 2 & 1 & -2 \end{bmatrix}$.

9. Să se determine descompunerea singulară a matricei $A = \begin{bmatrix} 2 & -2 \\ 1 & 1 \end{bmatrix}$ și aproximația A_1 a acesteia.

10. Determinați descompunerea singulară a matricei $A = \begin{bmatrix} 7 & 1 \\ 0 & 0 \\ 5 & 5 \end{bmatrix}$.